

אם WL הינה משפחה של פונקציות חלשים כפי שמופיע בהצגה.

אנו מניחים שעבור \mathcal{D} התפלגות $\mathcal{D}^{(t)}$ על \mathcal{S} האימון \mathcal{S}

נטרל מוצא פונקציה חלשה עבורו מתקיים:

$$\mathcal{E}_t = \sum_{i=1}^m D_i^{(t)} \cdot \mathbb{1}[y_i \neq h_t(x_i)] \leq \frac{1}{2}$$

כלומר, שגיאת האימון המשולפת עבור \mathcal{D} איננה t גבוהה מ-0.5.

לפי צמד האלמנטים $\mathcal{D}^{(t)} = (\frac{1}{m}, \dots, \frac{1}{m})$ נאמר - חלקה יוניפורמית. נט צמד t נמצא:

א. מוצא פונקציה חלשה $h_t \in WL(\mathcal{D}^{(t)}, \mathcal{S})$ הקיים את ההנחה.

(2) נחשב את השגיאה הממושלת \mathcal{E}_t לפי $\mathcal{D}^{(t)}$ על \mathcal{S}

(3) נחשב את המשל w_t הפונקציה החלשה h_t ע"י:

$$w_t = \frac{1}{2} \log\left(\frac{1}{\mathcal{E}_t} - 1\right)$$

(4) עדיין המשל w_t עבור האוגרזיה החדשה ע"י:

$$D_i^{(t+1)} = \frac{D_i^{(t)} \cdot \exp(-w_t \cdot y_i \cdot h_t(x_i))}{\sum_{j=1}^m D_j^{(t)} \cdot \exp(-w_t \cdot y_j \cdot h_t(x_j))}$$

עבור צמד של w_t בסדרה, נאמר את משל w_t כפי

לפחות רצופה מוצא w_t יותר באוגרזיה החדשה.

(5) נסכם את \mathcal{D} הממושלת (מציא את הסדרה).

$$\sum_{i=1}^m D_i^{(t)} \cdot e^{-y_i w_t + h_t(x_i)} =$$

ה.

$$= \sum_{i=1}^m D_i^{(t)} \cdot e^{-y_i w_t + h_t(x_i)} + \sum_{i=1}^m D_i^{(t)} \cdot e^{-y_i w_t + h_t(x_i)} =$$

$$y_i = h_t(x_i)$$

$$y_i \neq h_t(x_i)$$

$$= \sum_{i=1}^m D_i^{(t)} \cdot e^{-w_t} + \sum_{i=1}^m D_i^{(t)} \cdot e^{w_t} =$$

$$y_i = h_t(x_i)$$

$$y_i \neq h_t(x_i)$$

$$= e^{-w_t} \cdot \sum_{i=1}^m D_i^{(t)} + e^{w_t} \cdot \sum_{i=1}^m D_i^{(t)} =$$

$y_i = h_t(x_i)$ $y_i = h_t(x_i)$

↑
ε_t מנתון

$$e^{-w_t} \cdot (1 - \varepsilon_t) + e^{w_t} \cdot \varepsilon_t = e^{w_t} \cdot \varepsilon_t + \frac{(1 - \varepsilon_t)}{e^{w_t}} =$$

↑
w_t מנתון

$$\exp\left(\frac{1}{2} \log\left(\frac{1}{\varepsilon_t} - 1\right)\right) \cdot \varepsilon_t + \frac{(1 - \varepsilon_t)}{\exp\left(\frac{1}{2} \log\left(\frac{1}{\varepsilon_t} - 1\right)\right)} =$$

$$= \exp\left(\log\left(\sqrt{\frac{1 - \varepsilon_t}{\varepsilon_t}}\right)\right) \cdot \varepsilon_t + (1 - \varepsilon_t) \cdot \frac{1}{\exp\left(\log\left(\frac{1 - \varepsilon_t}{\varepsilon_t}\right)\right)} =$$

$$= \sqrt{\frac{1 - \varepsilon_t}{\varepsilon_t}} \cdot \varepsilon_t + \sqrt{\frac{\varepsilon_t}{1 - \varepsilon_t}} \cdot (1 - \varepsilon_t) = 2\sqrt{\varepsilon_t(1 - \varepsilon_t)}$$

(2) 0 ≤

$$1[y_i \neq \hat{h}(x_i)] = 0 \leq e^{-y_i f_t(x_i)} \quad \leftarrow y_i = \hat{h}(x_i) \text{ I}$$

אם $y_i \neq \hat{h}(x_i)$ אז $1[y_i \neq \hat{h}(x_i)] = 1$ ויש להוכיח ש- $e^{-y_i f_t(x_i)} \geq 1$

$$1[y_i \neq \hat{h}(x_i)] = 1 \quad \leftarrow y_i \neq \hat{h}(x_i) \text{ II}$$

$$y_i f_t(x_i) \leq 0 \quad \leftarrow \hat{h}(x_i) = \text{sign}(f_t(x_i)) \text{ נכון}$$

$$e^{-y_i f_t(x_i)} \geq e^0 = 1 = 1[y_i \neq \hat{h}(x_i)] \quad \leftarrow$$

$$\forall i \in [m]: 1[y_i \neq \hat{h}(x_i)] \leq e^{-y_i f_t(x_i)} \quad \leftarrow$$

$$L_S(\hat{h}) = \frac{1}{m} \sum_{i=1}^m 1[y_i \neq \hat{h}(x_i)] \leq \frac{1}{m} \sum_{i=1}^m e^{-y_i f_t(x_i)} = Z_t \quad \leftarrow$$

(2) $f_0(x_i) \equiv 0$ - נכון, $t=1$ נכון: הוכחה: $1[y_i \neq \hat{h}(x_i)] = 1$ ויש להוכיח ש- $e^{-y_i f_0(x_i)} \geq 1$

הוכחה: $f_0(x_i) \equiv 0$ - נכון, $t=1$ נכון: הוכחה: $1[y_i \neq \hat{h}(x_i)] = 1$ ויש להוכיח ש- $e^{-y_i f_0(x_i)} \geq 1$

$$\forall i: D_i^{(1)} = \frac{1}{m} = \frac{e^{-y_i \cdot 0}}{\sum_{j=1}^m e^{-y_j \cdot 0}} = \frac{e^{-y_i \cdot f_0(x_i)}}{\sum_{j=1}^m e^{-y_j \cdot f_0(x_j)}} \rightarrow D_i^{(1)} \propto e^{-y_i f_0(x_i)}$$

אם $t > 1$ נכון: הוכחה: $1[y_i \neq \hat{h}(x_i)] = 1$ ויש להוכיח ש- $e^{-y_i f_{t-1}(x_i)} \geq 1$

הוכחה: $f_{t-1}(x_i) \equiv 0$ - נכון, $t=1$ נכון: הוכחה: $1[y_i \neq \hat{h}(x_i)] = 1$ ויש להוכיח ש- $e^{-y_i f_{t-1}(x_i)} \geq 1$

$$D_i^{(t+1)} \propto D_i^{(t)} \cdot e^{-y_i w_t \cdot h_t(x_i)} \propto e^{-y_i f_{t-1}(x_i)} \cdot e^{-y_i w_t \cdot h_t(x_i)} =$$

↑

$$= e^{-y_i (f_{t-1}(x_i) + w_t h_t(x_i))} = e^{-y_i f_t(x_i)}$$

הכנסת
המשוואה

$$\frac{Z_t}{Z_{t-1}} = \frac{1}{m} \sum_{i=1}^m e^{-y_i f_t(x_i)} \cdot \frac{1}{\frac{1}{m} \sum_{i=1}^m e^{-y_i f_{t-1}(x_i)}} = \quad (3)$$

$$= \frac{\sum_{i=1}^m e^{-y_i (f_{t-1}(x_i) + w_t h_t(x_i))}}{\sum_{i=1}^m e^{-y_i f_{t-1}(x_i)}} =$$

$$= \frac{\sum_{i=1}^m e^{-y_i f_{t-1}(x_i)} \cdot e^{-y_i w_t h_t(x_i)}}{\sum_{i=1}^m e^{-y_i f_{t-1}(x_i)}} =$$

$$= \sum_{i=1}^m \left(\frac{e^{-y_i f_{t-1}(x_i)}}{\sum_{j=1}^m e^{-y_j f_{t-1}(x_j)}} \right) \cdot e^{-y_i w_t h_t(x_i)} =$$

$$\stackrel{(2)}{\underset{\approx 1}{\uparrow}} \sum_{i=1}^m D_i^{(t)} \cdot e^{-y_i w_t h_t(x_i)} \stackrel{\approx 1}{\underset{\approx 1}{\uparrow}} 2\sqrt{\epsilon_t(1-\epsilon_t)}$$

$$\forall t: \epsilon_t \leq \frac{1}{2} - \gamma \in [0, \frac{1}{2}] \quad \text{נניח} \quad (4)$$

$$2\sqrt{\epsilon_t(1-\epsilon_t)} \leq 2\sqrt{\left(\frac{1}{2}-\gamma\right) \cdot \left(\frac{1}{2}+\gamma\right)} = \sqrt{1-4\gamma^2} \quad \Leftarrow$$

$$[0, \frac{1}{2}] \quad \text{הפונקציה} \quad g(a) = a \cdot (1-a)$$

$$\sqrt{1-4\gamma^2} \leq \sqrt{e^{-4\gamma^2}} = e^{-\frac{4\gamma^2}{2}} = e^{-2\gamma^2} \quad \Leftarrow$$

\uparrow
 $1-a \leq e^{-a}$

$$2\sqrt{\epsilon_t(1-\epsilon_t)} \leq e^{-2\gamma^2} \quad \Leftarrow$$

נניח: (5)

$$Z_0 = \frac{1}{m} \sum_{i=1}^m e^{-y_i F_0(x_i)} = \frac{1}{m} \sum_{i=1}^m e^{-0} = 1$$

$$\prod_{t=1}^T \frac{Z_t}{Z_{t-1}} = \frac{Z_1}{Z_0} \cdot \frac{Z_2}{Z_1} \cdot \dots \cdot \frac{Z_{T-1}}{Z_{T-2}} \cdot \frac{Z_T}{Z_{T-1}} = \frac{Z_T}{Z_0}$$

הערות

$$\Rightarrow Z_T = \frac{Z_T}{1} = \frac{Z_T}{Z_0} = \prod_{t=1}^T \frac{Z_t}{Z_{t-1}}$$

$$L_S(\hat{h}) \leq Z_T = \prod_{t=1}^T \frac{Z_t}{Z_{t-1}} \leq \prod_{t=1}^T e^{-2\gamma^2} = e^{-2\gamma^2 T} \quad \Leftarrow$$

(1) קיבלנו

הפונקציה

(3) + (4) קיבלנו, נניח נ

$$\forall t: \epsilon_t \leq \frac{1}{2} - \gamma$$

3. מתקיים כי ההפסד של מפתח האמון נקיים:

$$L_S(\hat{h}) = \frac{1}{m} \cdot \sum_{i=1}^m 1 \cdot [y_i \neq \hat{h}(x_i)] \in \{0, \frac{1}{m}, \frac{2}{m}, \dots, \frac{m-1}{m}, 1\}$$

מההצגה:

$$L_S(\hat{h}) = 0 \text{ אולי מתקיים: } L_S(\hat{h}) < \frac{1}{m}$$

$$L_S(\hat{h}) = 0 \Leftrightarrow e^{-2\gamma^2 T} < \frac{1}{m} \text{ אולי מתקיים:}$$

נמצא את ה-T הנזקק כדי שמתקיים ה'

$$e^{-2\gamma^2 T} < \frac{1}{m}$$

$$\Rightarrow -2\gamma^2 T < \log\left(\frac{1}{m}\right) = -\log(m)$$

$$\Rightarrow T > \frac{\log m}{2\gamma^2} \Rightarrow T \geq \left\lceil 1 + \frac{\log m}{2\gamma^2} \right\rceil$$

$$\sum_{i=1}^m D_i^{(t+1)} \cdot 1[y_i \neq h_t(x_i)] =$$

הצגה

$$= \sum_{i=1}^m \frac{D_i^{(t)} e^{-w_t y_i h_t(x_i)}}{\sum_{j=1}^m D_j^{(t)} e^{-w_t y_j h_t(x_j)}} \cdot 1[y_i \neq h_t(x_i)] =$$

הצגה

$$= \frac{\sum_{i=1}^m D_i^{(t)} e^{-w_t y_i h_t(x_i)} \cdot 1[y_i \neq h_t(x_i)]}{2 \sqrt{E_t(1-E_t)}} \quad \leftarrow \begin{matrix} y_i = h_t(x_i) \Rightarrow \\ 1[y_i \neq h_t(x_i)] = 0 \end{matrix}$$

$$= \frac{\sum_{i=1}^m \frac{D_i^{(t)} \cdot e^{w_t}}{y_i \neq h_t(x_i)}}{2 \sqrt{E_t(1-E_t)}} = \frac{E_t e^{w_t}}{2 \sqrt{E_t(1-E_t)}} \quad \leftarrow \begin{matrix} \text{הצגה} \\ E_t \end{matrix} \quad \leftarrow \begin{matrix} \text{הצגה} \\ w_t \end{matrix}$$

$$= \frac{E_t \cdot e^{\frac{1}{2} \log\left(\frac{1}{E_t} - 1\right)}}{2 \sqrt{E_t(1-E_t)}} = \frac{E_t \sqrt{\frac{1-E_t}{E_t}}}{2 \sqrt{E_t(1-E_t)}} =$$

$$= \frac{\sqrt{E_t(1-E_t)}}{2 \sqrt{E_t(1-E_t)}} = \frac{1}{2}$$

Question 2:

```
In [25]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import sklearn.datasets
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
```

```
In [5]: df = pd.read_csv('winequality-red.csv', delimiter=';')
df['quality'] = (df['quality'] > 5).astype(int)
X, y = df.drop(columns=['quality']).to_numpy(), df['quality'].to_numpy()
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.40, random_state = 42)
```

1.

```
In [18]: dt = DecisionTreeClassifier(max_depth=12, random_state=0)
dt = dt.fit(X_train, y_train)
train_accuracy = accuracy_score(y_true=y_train, y_pred=dt.predict(X_train))
test_accuracy = accuracy_score(y_true=y_test, y_pred=dt.predict(X_test))
print(f"Train Accuracy: {train_accuracy*100:.2f}%")
print(f"Test Accuracy: {test_accuracy*100:.2f}%")
```

Train Accuracy: 98.96%
Test Accuracy: 72.81%

2.

```
In [38]: rf = RandomForestClassifier(n_estimators=100, max_depth=12, random_state=0)
rf = rf.fit(X_train, y_train)
train_accuracy = accuracy_score(y_true=y_train, y_pred=dt.predict(X_train))
test_accuracy = accuracy_score(y_true=y_test, y_pred=dt.predict(X_test))
print(f"Train Accuracy: {train_accuracy*100:.2f}%")
print(f"Test Accuracy: {test_accuracy*100:.2f}%")


values = []
n_estimators = list(range(1, 110, 10))

for n in n_estimators:
    rf = RandomForestClassifier(n_estimators=n, max_depth=12, random_state=0)
    rf = rf.fit(X_train, y_train)
    values.append(accuracy_score(y_true=y_test, y_pred=rf.predict(X_test)))

plt.plot(n_estimators, values)
plt.title('Test accuracy vs. Number of Estimators')
plt.xlabel('Num estimators')
plt.ylabel('Test Accuracy')
plt.show()
```

Train Accuracy: 99.90%

Test Accuracy: 80.16%



3.

```
In [47]: rf = RandomForestClassifier(n_estimators=100, max_depth=12, random_state=0, max_features=11)
rf = rf.fit(X_train, y_train)
train_accuracy = accuracy_score(y_true=y_train, y_pred=rf.predict(X_train))
test_accuracy = accuracy_score(y_true=y_test, y_pred=rf.predict(X_test))
print(f"Train Accuracy: {train_accuracy*100:.2f}%")
print(f"Test Accuracy: {test_accuracy*100:.2f}%")

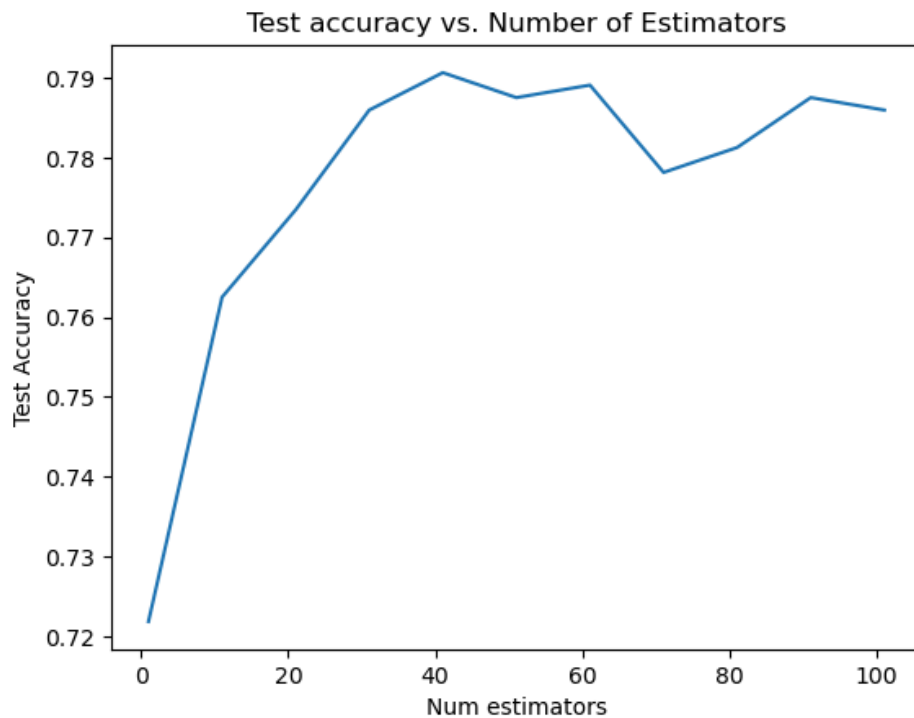
values = []
n_estimators = list(range(1, 110, 10))

for n in n_estimators:
    rf = RandomForestClassifier(n_estimators=n, max_depth=12, random_state=0, max_features=11)
    rf = rf.fit(X_train, y_train)
    values.append(accuracy_score(y_true=y_test, y_pred=rf.predict(X_test)))

plt.plot(n_estimators, values)
plt.title('Test accuracy vs. Number of Estimators')
plt.xlabel('Num estimators')
plt.ylabel('Test Accuracy')
plt.show()
```

Train Accuracy: 99.90%

Test Accuracy: 78.75%



4.

A) The model in section B is better than the model in section A because it has more regularization. Instead of relying on a single tree, we use the principle of bootstrapping and employ 100 trees.

B) The model in section C is worse than the model in section B because we don't prevent it from overfitting. The model uses all the features at every split, instead of just the square root of the number of features, which is the default value in the library.

5. a. הסיכוי כי הפיצול יהיה אחר הוא פיצול ג

כבר בהתפלגות ההיפוטזה קיבלנו למה (הסעיף החישום ניתן לראות)
שמצב זה - impurity עבור קודקוד ימין הוא אפס כולל הנגפים.
למרות שהפיצול ההיפוטזה על גורם מיומן, הפיצול הימני
מחזיר על עם מבדי impurity נמוכים יותר ולכן הוא עדיף.

b. פיצול $S_1 = 1$:

$$P_L^1 \left(\frac{150}{200} = \frac{3}{4}, \frac{50}{200} = \frac{1}{4} \right), P_R^1 = \left(\frac{1}{4}, \frac{3}{4} \right)$$

Entropy:

$$\begin{aligned} R_m^{\text{left}} &= \text{Entropy}(R_m^{\text{left}}) = \\ &= -\frac{1}{4} \log\left(\frac{1}{4}\right) - \frac{3}{4} \cdot \log\left(\frac{3}{4}\right) = 0.244 \end{aligned}$$

$$\begin{aligned} R_m^{\text{right}} &= \text{Entropy}(R_m^{\text{right}}) = \\ &= -\frac{1}{4} \log\left(\frac{1}{4}\right) - \frac{3}{4} \cdot \log\left(\frac{3}{4}\right) = 0.244 \end{aligned}$$

$$G(R_m, S_1) = \frac{1}{2} \cdot 0.244 + \frac{1}{2} \cdot 0.244 = 0.244$$

Gini:

$$\begin{aligned} R_m^{\text{left}} &= \text{Gini}(R_m^{\text{left}}) = \\ &= 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = \frac{3}{8} \end{aligned}$$

$$\begin{aligned} R_m^{\text{right}} &= \text{Gini}(R_m^{\text{right}}) = \\ &= 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = \frac{3}{8} \end{aligned}$$

$$G(R_m, S_1) = \frac{1}{2} \cdot \frac{3}{8} + \frac{1}{2} \cdot \frac{3}{8} = \frac{3}{8} = 0.375$$

$$\text{Misclassification: } R_m^{\text{left}} = \text{HmError}(R_m^{\text{left}}) =$$

$$= 1 - \max\left\{\frac{1}{4}, \frac{3}{4}\right\} = \frac{1}{4}$$

$$R_m^{\text{right}} = \text{HmError}(R_m^{\text{right}}) =$$

$$= 1 - \max\left\{\frac{1}{4}, \frac{3}{4}\right\} = \frac{1}{4}$$

$$G(R_m, S_1) = \frac{1}{2} \cdot \frac{1}{4} + \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{4} = 0.25$$

: S_2 : 2 סיביות

$$P_L^2 = \left(\frac{100}{300} = \frac{1}{3}, \frac{200}{300} = \frac{2}{3} \right), P_R^2 = \left(\frac{200}{100} = 1, \frac{0}{100} = 0 \right)$$

Entropy:

$$R_m^{\text{left}} = \text{Entropy}(R_m^{\text{left}}) =$$

$$= -\frac{1}{3} \log\left(\frac{1}{3}\right) - \frac{2}{3} \cdot \log\left(\frac{2}{3}\right) = 0.276$$

$$R_m^{\text{right}} = \text{Entropy}(R_m^{\text{right}}) =$$

$$= -1 \log(1) - 0 \cdot \log(0) = 0$$

$$G(R_m, S_2) = \frac{1}{2} \cdot 0 + \frac{2}{2} \cdot 0.276 = 0.138$$

Gini :

$$R_m^{\text{left}} = \text{Gini}(R_m^{\text{left}}) =$$

$$= 2 \cdot \frac{1}{3} \cdot \frac{2}{3} = \frac{4}{9}$$

$$R_m^{\text{right}} = \text{Gini}(R_m^{\text{right}}) =$$

$$= 2 \cdot 1 \cdot 0 = 0$$

$$G(R_m, S_2) = \frac{1}{2} \cdot 0 + \frac{2}{2} \cdot \frac{4}{9} = \frac{1}{3} = 0.333$$

Misclassification: $R_m^{\text{left}} = \text{H.M. Error}(R_m^{\text{left}}) =$

$$= 1 - \max\left\{\frac{2}{3}, \frac{1}{3}\right\} = \frac{1}{3}$$

$$R_m^{\text{right}} = \text{H.M. Error}(R_m^{\text{right}}) =$$

$$= 1 - \max\{1, 0\} = 0$$

$$G(R_m, S_2) = \frac{2}{4} \cdot \frac{1}{3} + \frac{1}{4} \cdot 0 = \frac{1}{4} = 0.25$$

המבחן שאנו מוסיף מבחן החלוקה הוא Misclassification Rate

שני המבחנים האחרים מתחשבים בהתפלגות של הקלאסים

בעוד ש-Misclassification Rate מתחשב רק בקלאסים המקסימלי בקורקט.

כתוצאה מכך, ואין ביטוי ל"ערבוב" הקלאסים בט קורקט.

כפי שראינו במישימים, המבחן החזיר תוצאות זהה עבור שני

ביצורים שונים למבחן.